CENTRO UNIVERSITÁRIO DE BALSAS - UNIBALSAS
CURSO DE ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

CAIO VINÍCIUS LIMA SOARES
DAVID RODRIGUES COSTA
FRANCISCO WESLEY DE SOUZA DIAS
PEDRO HENRIQUE GUEDES

STUDYTRACK IA: SELEÇÃO, PREPARAÇÃO, ANÁLISE E MODELAGEM DE DADOS

TED 03 - BIG DATA E CIÊNCIAS DE DADOS

Balsas - MA
2026

SUMÁRIO

1 INTRODUÇÃO 3
2 PROBLEMA E SOLUÇÃO 3
3 NECESSIDADES DE DADOS 4
4 CONJUNTO DE DADOS SELECIONADO 4
5 PRINCIPAIS VARIÁVEIS 5
6 JUSTIFICATIVA DA ESCOLHA 5
7 QUALIDADE E LIMITAÇÕES IDENTIFICADAS NA TED 01 5
8 LIMPEZA E PREPARAÇÃO DOS DADOS 6
8.1 Inspeção inicial 6
8.2 Tratamentos realizados 6
8.3 Base preparada 7
9 ANÁLISE EXPLORATÓRIA DE DADOS 7
9.1 Distribuição da nota final 7
9.2 Horas semanais de estudo 9
9.3 Frequência às aulas 10
9.4 Impacto de projetos e atividades 11
9.5 Desempenho do semestre anterior 12
9.6 Relações entre as variáveis 12
10 RELAÇÃO DOS RESULTADOS COM O PROBLEMA E O MVP 13
11 LIMITAÇÕES DA ANÁLISE 13
12 SÍNTESE DA TED 02 13
13 DEFINIÇÃO DO PROBLEMA DE MACHINE LEARNING 13
14 DADOS, VARIÁVEL-ALVO E SELEÇÃO DE ATRIBUTOS 14
15 PRÉ-PROCESSAMENTO E PREVENÇÃO DE VAZAMENTO 15
16 ALGORITMOS E PROTOCOLO DE AVALIAÇÃO 15
17 RESULTADOS EXPERIMENTAIS 16
17.1 Comparação dos classificadores na validação cruzada 16
17.2 Modelo selecionado e teste reservado 17
17.3 Matriz de confusão 18
17.4 Relatório de classificação por classe 19
18 INTERPRETAÇÃO DOS RESULTADOS E LIMITAÇÕES 19
19 PRIVACIDADE, REPRODUTIBILIDADE E RELAÇÃO COM O MVP 20
20 CONCLUSÃO DA TED 03 20
REFERÊNCIAS BIBLIOGRÁFICAS 21

1 INTRODUÇÃO

O projeto StudyTrack IA foi desenvolvido com o objetivo de auxiliar estudantes na organização e priorização de suas atividades acadêmicas. A proposta reúne disciplinas, avaliações, trabalhos e compromissos em um ambiente de acompanhamento.

Na TED 01 foram identificadas as necessidades de informação e selecionada uma base pública de desempenho acadêmico. A TED 02 analisou a qualidade dessa base, padronizou variáveis e investigou relações entre hábitos de estudo e notas. A TED 03 acrescentou classificação multiclasse, comparação de algoritmos e avaliação em teste reservado, preservando os registros das etapas anteriores.

2 PROBLEMA E SOLUÇÃO

A rotina universitária envolve diversas disciplinas, avaliações, atividades e prazos. Essa multiplicidade pode dificultar o acompanhamento dos compromissos e a definição de prioridades.

O StudyTrack IA propõe cadastro de disciplinas e atividades, acompanhamento de prazos, calendário, indicação de prioridade e painel acadêmico. A base escolhida para Big Data contribui para estudar hábitos e desempenho, mas não contém todos os atributos necessários à priorização, como prazos individuais, datas de entrega e características específicas das tarefas. Dessa forma, a modelagem desenvolvida nesta etapa está relacionada à classificação do desempenho acadêmico, não à implementação ou validação de um mecanismo automático de priorização.

Assim, a análise dos dados contribui para a compreensão de fatores associados ao desempenho estudantil e para o desenvolvimento técnico do projeto, respeitando as limitações do conjunto de dados utilizado.

3 NECESSIDADES DE DADOS

Informação	Relação com o projeto
Horas de estudo	Analisar a dedicação acadêmica
Frequência às aulas	Acompanhar a participação nas aulas
Preparação para provas	Investigar hábitos de planejamento
Projetos e atividades	Considerar o contexto das tarefas acadêmicas
Desempenho anterior	Acompanhar o histórico acadêmico
Nota final	Representar a classe de desempenho obtida

Esses dados permitem investigar fatores associados ao desempenho acadêmico. O MVP exige ainda informações próprias sobre prazo, peso, status e esforço estimado das atividades.

4 CONJUNTO DE DADOS SELECIONADO

O conjunto Higher Education Students Performance Evaluation foi obtido no UCI Machine Learning Repository. A base contém registros de estudantes do ensino superior e atributos relacionados a hábitos de estudo, condições familiares e desempenho.

Característica	Informação
Fonte	UCI Machine Learning Repository
Registros	145
Preditoras	31
Variável-alvo	GRADE (0 a 7)
Formato	CSV; dados tabulares codificados
Contexto	Ensino superior
Licença	Creative Commons Attribution 4.0
Valores ausentes	Nenhum, confirmado na TED 02

5 PRINCIPAIS VARIÁVEIS

Variável	Aplicação analítica
Horas semanais de estudo	Analisar a dedicação declarada
Frequência às aulas	Investigar participação acadêmica
Preparação para avaliações	Identificar hábitos de estudo
Impacto de projetos e atividades	Observar percepções sobre atividades acadêmicas
GPA do semestre anterior	Considerar o histórico acadêmico
Course ID	Identificar o curso na base
GRADE	Classificar o desempenho final

Os códigos devem ser interpretados conforme a documentação da UCI. Embora armazenados como inteiros, muitos atributos representam categorias nominais ou ordinais, e não medidas contínuas.

6 JUSTIFICATIVA DA ESCOLHA

A escolha da base decorre da relação entre hábitos, frequência, preparação e desempenho acadêmico. A estrutura permite inspeção, análise exploratória e comparação de classificadores em Python. O conjunto, entretanto, não registra prazos, peso de avaliações ou prioridade de tarefas; sua contribuição ao MVP está principalmente na compreensão e no acompanhamento do desempenho.

7 QUALIDADE E LIMITAÇÕES IDENTIFICADAS NA TED 01

A TED 01 registrou que, segundo a UCI, o conjunto possui 145 observações e não apresenta valores ausentes. Também apontou a amostra pequena e o contexto educacional específico como limitações para generalização. Essas informações foram verificadas e aprofundadas na TED 02.

8 LIMPEZA E PREPARAÇÃO DOS DADOS

8.1 Inspeção inicial

A análise da TED 02 encontrou 145 registros e 33 colunas na base original: identificador de estudante, 30 atributos codificados, identificador do curso e nota final. Os 145 identificadores eram distintos.

Verificação	Resultado
Registros	145
Colunas originais	33
Valores ausentes	0
Duplicados	0
Duplicados sem STUDENT ID	0
Identificadores únicos	145
Códigos fora das faixas	0

8.2 Tratamentos realizados

Como não foram identificados valores ausentes, duplicatas ou códigos inválidos, não houve exclusão de registros nem imputação. As colunas numéricas foram renomeadas com nomes descritivos; seus códigos originais permaneceram. O identificador STUDENT ID foi mantido na base tratada para rastreabilidade e excluído da versão destinada à modelagem.

Questão	Decisão na TED 02	Justificativa
Ausentes	Sem imputação	Não havia valores faltantes
Duplicatas	Sem remoção	Nenhuma ocorrência encontrada
Nomes das variáveis	Padronizados	Melhorar a leitura e a reprodução
STUDENT ID	Excluído da modelagem	Identificador sem papel preditivo
Categorias raras	Preservadas	Evitar redução adicional da base
Outliers	Sem exclusão automática	Códigos categóricos não são medidas contínuas

8.3 Base preparada

A versão de modelagem contém 145 registros, 31 variáveis preditoras e a coluna grade. Nenhuma observação foi excluída. O arquivo dataset_modelagem.csv está disponível no repositório StudyTrack_IA.

9 ANÁLISE EXPLORATÓRIA DE DADOS

9.1 Distribuição da nota final

A variável grade possui oito classes, de 0 (Fail) a 7 (AA). A classe DD apresentou 35 registros (24,1%), e a classe Fail, apenas 8 (5,5%). O desequilíbrio é relevante para a etapa de classificação.

Classe	Significado	Quantidade	Percentual
0	Fail	8	5,5%
1	DD	35	24,1%
2	DC	24	16,6%
3	CC	21	14,5%
4	CB	10	6,9%
5	BB	17	11,7%
6	BA	13	9,0%
7	AA	17	11,7%

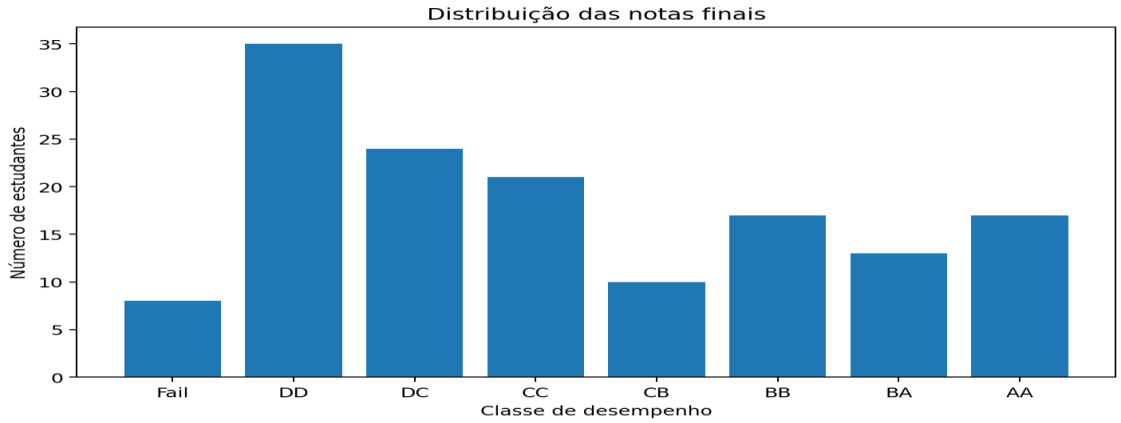


Figura 1 – Distribuição das classes de nota final. Fonte: TED 02, StudyTrack IA.

O gráfico evidencia que a classe DD concentra o maior número de estudantes, seguida por DC e CC, enquanto Fail e CB aparecem com poucos registros. Essa distribuição desigual é relevante para a classificação, pois as classes pouco representadas oferecem menos exemplos para o aprendizado. Assim, um modelo pode acertar bem as classes mais frequentes sem reconhecer as demais, o que justifica o uso do F1-macro, que atribui peso equivalente a todas as classes.

9.2 Horas semanais de estudo

Na TED 02, 74 estudantes declararam estudar menos de cinco horas semanais. As médias de classe não apresentaram progressão linear simples: o grupo de menos de cinco horas teve média de 3,45 e o grupo de mais de vinte horas, com apenas quatro casos, média de 2,00.

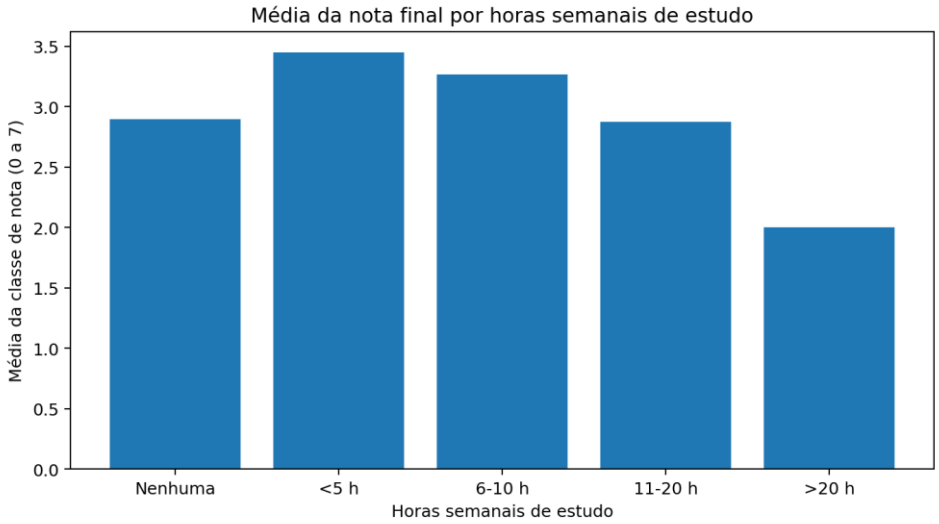


Figura 2 – Média da nota final por horas de estudo. Fonte: TED 02, StudyTrack IA.

O gráfico mostra que a maior média aparece no grupo que estuda menos de cinco horas semanais e que as médias diminuem nas faixas de 6 a 10 horas e de 11 a 20 horas, sem formar uma sequência crescente com o tempo de estudo. Como algumas categorias reúnem poucos estudantes, as diferenças entre as barras devem ser lidas com cautela, pois médias calculadas com poucos casos são mais sensíveis a valores individuais. Os resultados descrevem a amostra e não permitem concluir que mais horas de estudo aumentem ou reduzam a nota.

9.3 Frequência às aulas

A base de dados apresentou 145 estudantes, dos quais 110 pertenciam à categoria “sempre” e 35 à categoria “às vezes”. As médias da variável de classe foram de 3,40 e 2,69, respectivamente. Embora os valores indiquem uma diferença descritiva entre os grupos, ela não permite, por si só, estabelecer relação causal.

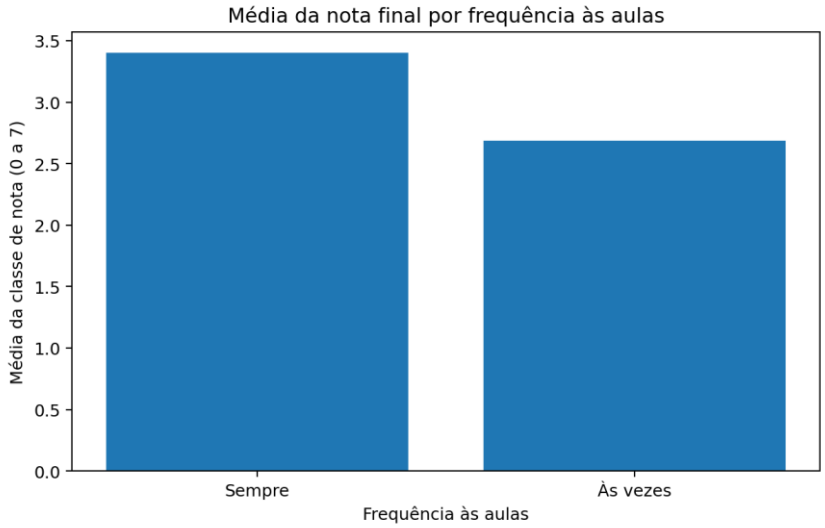


Figura 3 – Média da nota final por frequência às aulas. Fonte: TED 02, StudyTrack IA.

O gráfico torna visível a diferença entre as barras: estudantes que frequentam as aulas sempre registraram média de classe superior à dos que frequentam às vezes. Como o grupo “às vezes” reúne bem menos estudantes que o grupo “sempre”, a comparação deve ser interpretada com cautela. O resultado indica uma associação descritiva nesta amostra e não permite afirmar que a frequência às aulas, isoladamente, explique a diferença observada na nota final.

9.4 Impacto de projetos e atividades

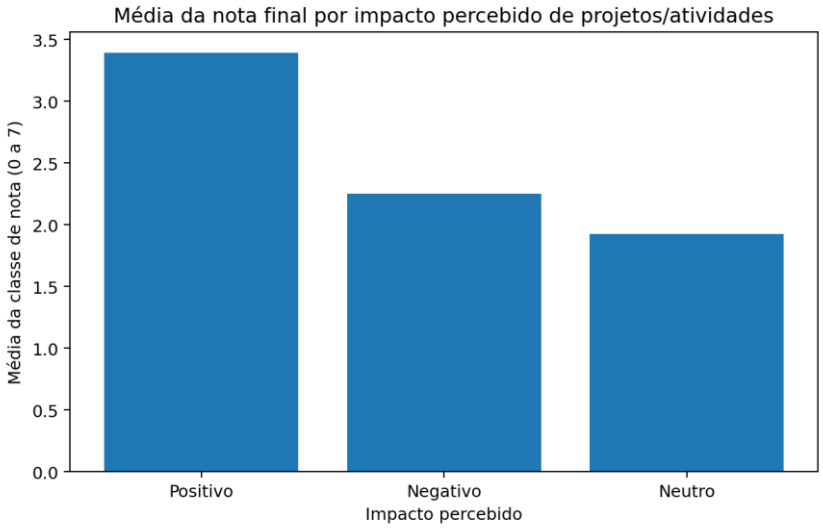


Figura 4 – Impacto percebido de projetos e atividades. Fonte: TED 02, StudyTrack IA.

No gráfico, os estudantes que perceberam impacto positivo de projetos e atividades apresentaram a maior média de classe, acima de 3,0, enquanto as categorias negativo e neutro ficaram em valores próximos de 2,0, com o grupo neutro ligeiramente abaixo do negativo. Essa diferença é coerente com o valor de V de Cramér de 0,201 registrado para o impacto de atividades, o segundo maior entre os atributos citados na seção 9.6. Por se tratar de uma percepção declarada e de uma associação descritiva, os resultados não indicam que as atividades causem a variação da nota.

9.5 Desempenho do semestre anterior

O histórico acadêmico apresentou diferenças mais consistentes: na faixa de GPA anterior superior a 3,49, a média de classe final foi 4,24, enquanto as duas faixas inferiores tiveram médias próximas de 2,24 e 2,29.

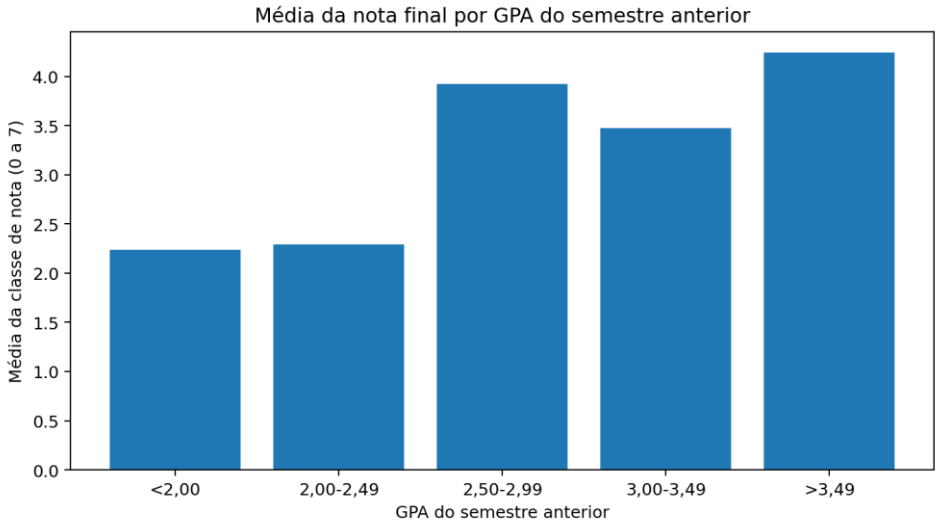


Figura 5 – Média da nota final por faixa de GPA anterior. Fonte: TED 02, StudyTrack IA.

O gráfico indica que as duas faixas de GPA anterior inferiores a 2,50 concentram as menores médias de classe, enquanto as faixas a partir de 2,50 apresentam médias mais altas, com o maior valor na faixa superior a 3,49. A progressão não é perfeitamente regular, pois a faixa de 2,50 a 2,99 aparece acima da faixa de 3,00 a 3,49. Ainda assim, o conjunto é coerente com o maior valor de V de Cramér (0,262) entre os atributos da seção 9.6, sem implicar relação causal.

9.6 Relações entre as variáveis

A TED 02 utilizou V de Cramér para descrever associações entre categorias e a nota final. Entre os atributos relacionados ao projeto, foram registrados aproximadamente: GPA anterior (0,262), impacto de atividades (0,201), GPA esperado na graduação (0,169), horas de estudo (0,144) e frequência (0,138). As associações não representam efeitos causais.

10 RELAÇÃO DOS RESULTADOS COM O PROBLEMA E O MVP

Os resultados da TED 02 sugerem que o histórico acadêmico, a participação em aula e a percepção sobre atividades oferecem informações de contexto para acompanhamento do estudante. O tempo de estudo, isoladamente, não apresentou relação linear simples com a classe final.

Para priorizar atividades no StudyTrack IA, será necessário acrescentar dados produzidos pelo próprio sistema, como prazo, disciplina, peso, status e esforço estimado. A base atual permite investigar classificação de desempenho, não o mecanismo integral de priorização.

11 LIMITAÇÕES DA ANÁLISE

A base contém apenas 145 registros e foi coletada em um contexto educacional específico. Vários atributos são categóricos ou autorrelatados. Certas categorias apresentam poucos exemplos, o que limita comparações e torna inadequada a generalização dos achados.

12 SÍNTESE DA TED 02

A segunda etapa confirmou a integridade da base e preparou uma versão sem identificador pessoal para modelagem. A análise exploratória apontou associações entre hábitos acadêmicos e desempenho, com maior destaque para o histórico escolar. Essas evidências justificam investigar técnicas de classificação na TED 03, mantendo as limitações já identificadas.

13 DEFINIÇÃO DO PROBLEMA DE MACHINE LEARNING

A TED 03 investiga um problema de classificação supervisionada multiclasse da variável grade, que representa a nota final codificada em oito categorias (0 = Fail; 1 = DD; 2 = DC; 3 = CC; 4 = CB; 5 = BB; 6 = BA; 7 = AA). O experimento é retrospectivo: utiliza atributos registrados na base histórica e não comprova

capacidade de antecipar notas antes de todas essas informações estarem disponíveis.

A modelagem dá continuidade às TEDs 01 e 02 e mantém o objetivo acadêmico de comparar métodos, analisar erros e reconhecer limites de generalização. Não se deve interpretar a classificação de grade como implementação do sistema de priorização de tarefas do MVP.

14 DADOS, VARIÁVEL-ALVO E SELEÇÃO DE ATRIBUTOS

A base preparada data/processed/dataset_modelagem.csv contém 145 registros e 32 colunas: 31 variáveis preditoras e a coluna-alvo grade. O identificador student_id foi excluído do conjunto de preditoras para evitar seu uso como sinal identificador. A divisão estratificada de 80% para treinamento e 20% para teste reservou 116 e 29 observações, respectivamente.

Foram mantidas as 31 variáveis preditoras conforme o protocolo da etapa. Elas contemplam informações sobre estudos, frequência, GPA anterior e esperado, condições pessoais e familiares e identificador de curso. A presença de uma variável no experimento não implica relevância comprovada nem adequação automática para uso no MVP.

Item	Configuração registrada
Fonte	UCI — Higher Education Students Performance Evaluation
Arquivo de modelagem	data/processed/dataset_modelagem.csv
Registros	145
Preditoras	31
Variável-alvo	grade (8 classes)
Treino / teste	116 / 29 (estratificado 80/20)
Semente	42

15 PRÉ-PROCESSAMENTO E PREVENÇÃO DE VAZAMENTO

A base combina 16 atributos nominais e 15 ordinais. Os nominais foram codificados com OneHotEncoder(handle_unknown="ignore"), enquanto os códigos ordinais foram preservados como ordenações. Na Regressão Logística, os atributos ordinais receberam padronização com StandardScaler; nos modelos baseados em árvores, a padronização não foi aplicada.

A transformação foi organizada em pipelines, de modo que cada ajuste fosse realizado dentro da respectiva partição de treinamento durante a validação cruzada. Os 29 registros reservados não participaram da comparação de modelos. Esse cuidado reduz o risco de vazamento de dados, embora não elimine outros limites metodológicos da amostra.

Grupo de atributos	Quantidade	Tratamento
Nominais	16	One-Hot Encoding; ignorar categorias novas
Ordinais	15	Códigos preservados; escalonamento apenas na Regressão Logística
Identificador pessoal	1 (student_id)	Excluído dos preditores
Alvo	1 (grade)	Categorias 0 a 7 sem escalonamento

16 ALGORITMOS E PROTOCOLO DE AVALIAÇÃO

Foram comparados três classificadores: Regressão Logística, Árvore de Decisão e Random Forest. A avaliação utilizou validação cruzada estratificada de cinco partes (StratifiedKFold, shuffle=True, random_state=42) exclusivamente nos 116 exemplos de treinamento. A métrica principal de seleção foi a média do F1-macro, complementada pela acurácia média. O F1-macro dá peso equivalente a todas as classes, característica relevante diante do desequilíbrio da variável-alvo.

A regra técnica de seleção foi identificar o maior F1-macro médio na validação cruzada e somente depois avaliar esse classificador no teste reservado. Essa

sequência separa comparação de modelos e avaliação final, evitando escolher um modelo a partir do desempenho nos 29 exemplos de teste.

17 RESULTADOS EXPERIMENTAIS

17.1 Comparação dos classificadores na validação cruzada

A comparação publicada no repositório apresenta os resultados abaixo, calculados no conjunto de treinamento. O Random Forest obteve o maior F1-macro médio (0,227408). A diferença numérica em relação aos demais modelos é pequena e os desvios observados entre as partes limitam afirmações de superioridade geral.

Classificador	F1-macro CV (± DP)	Acurácia CV (± DP)	F1 no treino
Random Forest	0,227408 ± 0,057315	0,311232 ± 0,074522	1,000000
Árvore de Decisão	0,208232 ± 0,071473	0,242391 ± 0,074874	1,000000
Regressão Logística	0,207314 ± 0,054845	0,276812 ± 0,081405	0,985632

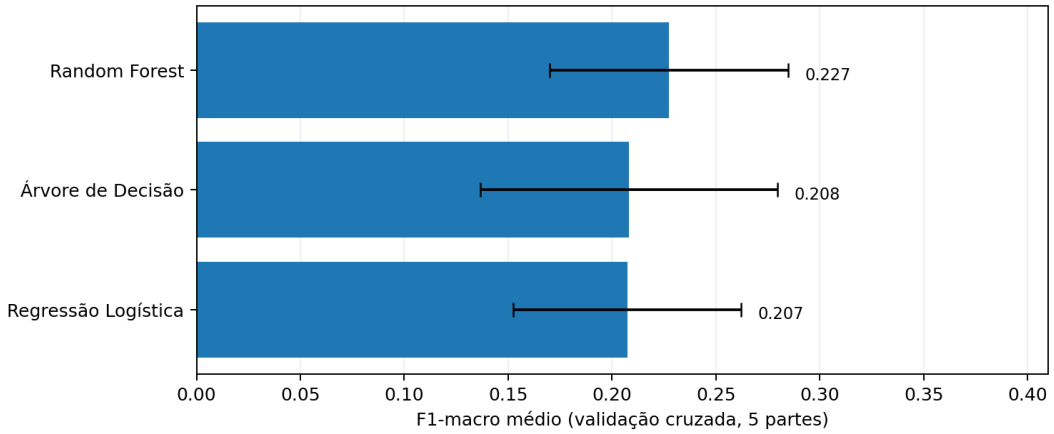


Figura 6 – F1-macro médio e desvio-padrão na validação cruzada. Fonte: resultados técnicos da TED 03 publicados no GitHub.

No gráfico, o Random Forest apresentou o maior F1-macro médio na validação cruzada (0,227), seguido pela Árvore de Decisão (0,208) e pela Regressão Logística (0,207). Entretanto, as diferenças entre os modelos são

pequenas e as barras de desvio-padrão se sobrepõem, o que não permite afirmar superioridade geral do Random Forest. Os valores absolutos também são modestos para uma tarefa de oito classes, o que reforça a cautela na interpretação dos resultados.

17.2 Modelo selecionado e teste reservado

Aplicando a regra técnica de maior F1-macro médio, o Random Forest foi ajustado aos 116 registros de treinamento e avaliado uma vez nos 29 registros reservados. A reprodução local publicada apresenta 11 classificações corretas, acurácia de 0,379310 (37,93%) e F1-macro de 0,288095. A contagem de acertos e as métricas foram conferidas por recálculo aritmético da matriz de confusão publicada.

Indicador no teste	Resultado
Registros avaliados	29
Previsões corretas	11
Previsões incorretas	18
Acurácia	0,379310 (37,93%)
F1-macro	0,288095
Classes	8

17.3 Matriz de confusão

A matriz apresenta nas linhas as classes reais e nas colunas as classes previstas. A soma dos elementos é 29 e a diagonal principal soma 11, coerente com a acurácia informada.

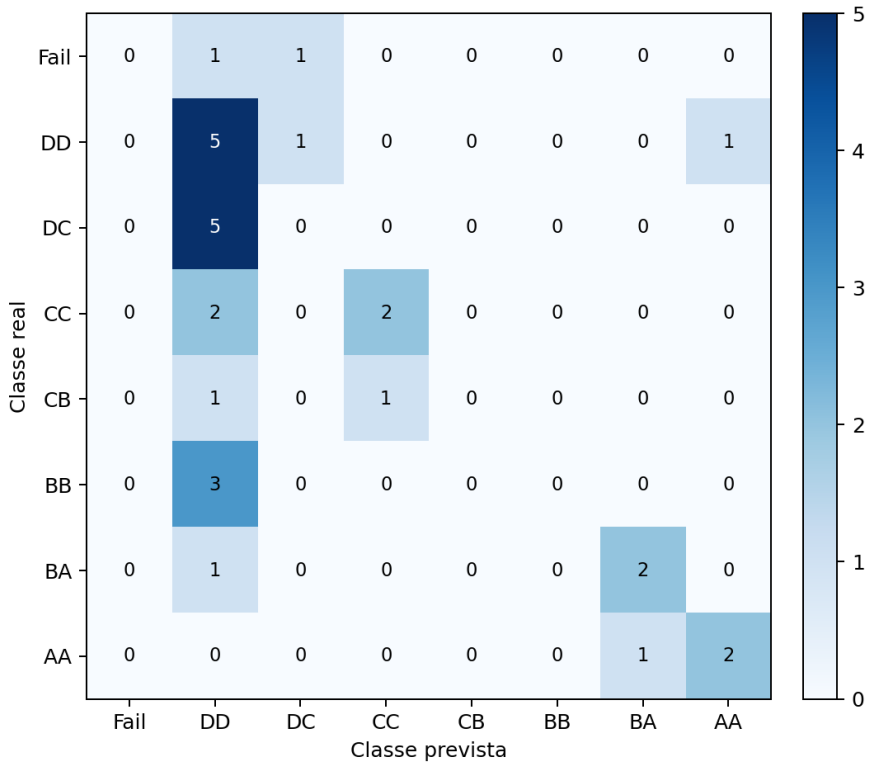


Figura 7 – Matriz de confusão do Random Forest no teste reservado. Fonte: resultados técnicos publicados, visualização derivada da matriz registrada.

A matriz mostra 11 acertos na diagonal principal e 18 erros entre os 29 registros de teste. Os acertos aparecem nas classes DD (5), CC (2), BA (2) e AA (2), enquanto nenhum registro de Fail, DC, CB ou BB foi classificado corretamente. Dos 18 erros, 13 correspondem a registros previstos como DD, incluindo os cinco exemplos de DC e os três de BB. Esse padrão é compatível com o desequilíbrio de classes e com os pequenos suportes por classe, que limitam a estabilidade do modelo.

17.4 Relatório de classificação por classe

Classe	Precisão	Recall	F1-score	Suporte
Fail	0.000	0.000	0.000	2
DD	0.278	0.714	0.400	7
DC	0.000	0.000	0.000	5
CC	0.667	0.500	0.571	4
CB	0.000	0.000	0.000	2
BB	0.000	0.000	0.000	3
BA	0.667	0.667	0.667	3
AA	0.667	0.667	0.667	3

Não houve acertos no teste para as classes Fail, DC, CB e BB. O recall de DD foi 0,714, mas sua precisão foi de aproximadamente 0,278: o modelo atribuiu com frequência essa classe também a exemplos de outras categorias. As classes com apenas dois ou três exemplos apresentam indicadores especialmente instáveis.

18 INTERPRETAÇÃO DOS RESULTADOS E LIMITAÇÕES

O desempenho no teste foi reduzido para uma tarefa de oito classes. O F1-macro de 0,288095 indica dificuldade em reconhecer de forma equilibrada as diferentes categorias. A discrepância entre F1 no treinamento, próximo de 1, e os F1-macro médios de validação cruzada, em torno de 0,21 a 0,23, é compatível com risco de sobreajuste. Por essa razão, uma pontuação elevada no conjunto de treinamento não constitui evidência suficiente de generalização.

A amostra de 145 observações, a distribuição desigual das categorias, os pequenos suportes por classe e o contexto específico de coleta limitam a estabilidade das métricas. Não foram apresentados testes externos em outra instituição, análise de calibração ou auditoria de equidade por subgrupos. As associações descritivas da TED 02 não devem ser transformadas em explicações causais do desempenho.

19 PRIVACIDADE, REPRODUTIBILIDADE E RELAÇÃO COM O MVP

O estudo utiliza um conjunto de dados público, com licença CC BY 4.0. O identificador student_id não participa das preditoras; essa exclusão, isoladamente, não garante anonimização completa. Uma eventual aplicação com dados reais de estudantes exigiria finalidade definida, minimização, controle de acesso, transparência, proteção das informações e demais cuidados compatíveis com a Lei Geral de Proteção de Dados (LGPD). Variáveis familiares e demográficas podem introduzir vieses e demandam análise antes de qualquer aplicação prática.

Conforme a documentação e os experimentos, a base de desempenho acadêmico não contém prazos, pesos, status, disciplinas ou esforço previsto de tarefas.

20 CONCLUSÃO DA TED 03

A TED 03 ampliou o trabalho iniciado nas duas etapas anteriores por meio de uma classificação supervisionada multiclasse. Com 31 preditoras, pré-processamento misto e divisão estratificada 116/29, foram comparados três algoritmos mediante validação cruzada de cinco partes. O Random Forest apresentou o maior F1-macro médio (0,227408). Na reprodução local do teste reservado, registrou F1-macro de 0,288095 e acurácia de 37,93%, correspondentes a 11 acertos em 29 observações.

Os indicadores evidenciam dificuldades de previsão em várias classes e risco de sobreajuste. A amostra pequena e o contexto específico de coleta não autorizam a generalização dos resultados. O experimento constitui uma avaliação retrospectiva documentada, sem comprovar previsão antecipada ou ganho operacional na priorização de atividades do MVP. Ainda assim, o processo oferece subsídios técnicos para a análise crítica de dados, algoritmos, vieses e limites de aplicação.
O repositório para acesso https://github.com/Francisco-alt-coder/StudyTrack_IA.git

REFERÊNCIAS BIBLIOGRÁFICAS

PEDREGOSA, Fabian et al. **Scikit-learn: Machine Learning in Python**. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011. Disponível em: https://jmlr.org/papers/v12/pedregosa11a.html.

SCIKIT-LEARN DEVELOPERS. Cross-validation: evaluating estimator performance. Disponível em: https://scikit-learn.org/stable/modules/cross_validation.html.

SCIKIT-LEARN DEVELOPERS. **DecisionTreeClassifier**. Scikit-learn Documentation. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html.

SCIKIT-LEARN DEVELOPERS. **f1_score**. Scikit-learn Documentation. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html.

SCIKIT-LEARN DEVELOPERS. **LogisticRegression**. Scikit-learn Documentation. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html.

YILMAZ, Nevriye; ŞEKEROĞLU, Boran. Higher Education Students Performance Evaluation. UCI Machine Learning Repository. Dados coletados em 2019; disponibilização em 2023. DOI: https://doi.org/10.24432/C51G82. Disponível em: https://archive.ics.uci.edu/dataset/856/higher+education+students+performance+evaluation.