STUDYTRACK IA: seleção, preparação, análise e modelagem de dados

Documento Técnico v3.0 — versão acumulativa consolidada para conferência acadêmica Instituição: Centro Universitário de Balsas (UNIBALSAS) Curso: Análise e Desenvolvimento de Sistemas — 2026.2 Disciplina: Big Data e Ciências de Dados Professor: Alex Rogaleski Marques Autores: Caio Vinícius Lima Soares; David Rodrigues Costa; Francisco Wesley de Souza Dias; Pedro Henrique Guedes. Local e data: Balsas, MA, 02 de novembro de 2026.

> Condição de uso: consolidação de registros já existentes das TEDs 01, 02 e 03, para conferência da equipe. Não constitui aprovação formal pelo professor ou validação coletiva documentada. O notebook foi executado localmente; execução no Google Colab não foi comprovada. Não se alteraram os resultados já publicados. Os PDFs originais das TEDs 01 e 02 permanecem no repositório como evidências integrais das etapas anteriores.

1. Introdução

O StudyTrack IA propõe apoiar estudantes na organização de disciplinas, avaliações, atividades e prazos. A pesquisa em Big Data e Ciências de Dados foi estruturada em etapas cumulativas: seleção do problema e dos dados (TED 01), preparação e análise exploratória (TED 02) e modelagem e avaliação (TED 03). A classificação de notas históricas nesta etapa é retrospectiva, não uma previsão antecipada nem a validação do sistema de priorização de tarefas.

2. Problema e solução propostos

O problema do projeto é a dificuldade de conciliar disciplinas, avaliações, trabalhos e prazos. O MVP prevê cadastro e acompanhamento de disciplinas e atividades, calendário, visualização de prioridades e painel acadêmico. A análise de dados de desempenho complementa a compreensão do contexto educacional, mas não constitui o algoritmo central de prioridade do MVP.

3. Necessidades de dados

Informação	Finalidade da investigação
Horas de estudo	Caracterização da dedicação acadêmica
Frequência às aulas	Participação acadêmica
Preparação para avaliações	Hábitos de organização e estudo
Projetos e atividades	Percepção de impacto sobre o desempenho
Desempenho anterior e notas	Classificação retrospectiva de grade

Para validar a priorização efetiva de atividades, o MVP ainda precisará de dados próprios de tarefas: prazos, pesos, disciplinas, status e esforço previsto. A base acadêmica selecionada não contém essas variáveis operacionais.

4. Conjunto de dados selecionado

A TED 01 selecionou Higher Education Students Performance Evaluation, do UCI Machine Learning Repository, com 145 observações e 31 atributos preditores. O CSV de origem contém 33 colunas, incluindo student_id e grade. A versão utilizada na modelagem possui 32 colunas: as 31 preditoras e o alvo grade.

- Fonte: UCI Machine Learning Repository, DOI 10.24432/C51G82 (https://doi.org/10.24432/C51G82).
- Formato: CSV.
- Licença informada no material: CC BY 4.0.
- Base de modelagem: data/processed/dataset_modelagem.csv.
- Hash Git da base preparada verificado nos registros técnicos: 7859d534e981355b852a520b5e745aac121f9489.

5. Variáveis principais

O conjunto contempla hábitos de estudo, leitura, frequência às aulas, preparação para provas, GPA do semestre anterior, expectativa de GPA, percepção sobre projetos e características acadêmicas, pessoais e familiares. A variável-alvo grade apresenta oito classes: 0=Fail, 1=DD, 2=DC, 3=CC, 4=CB, 5=BB, 6=BA e 7=AA.

Os códigos de classes são usados como categorias de classificação e não como medidas contínuas.

6. Justificativa da base e dos atributos

A base é pública, foi utilizada nas etapas anteriores e contém variáveis relacionadas ao contexto de desempenho acadêmico. A TED 03 manteve as 31 preditoras, conforme protocolo previamente registrado pela equipe, para comparar três técnicas sob o mesmo conjunto de atributos, sem selecionar variáveis após observar os resultados do teste. A decisão não demonstra que todas as variáveis sejam igualmente relevantes, nem substitui uma análise futura de importância de atributos. Características demográficas e socioeconômicas demandam especial cautela quanto a vieses e privacidade.

A base não tem prazo, peso nem status de tarefa, portanto não pode avaliar diretamente a qualidade das prioridades geradas pelo MVP.

7. Qualidade e limitações levantadas na TED 01

A etapa inicial identificou 145 observações, predomínio de variáveis categóricas e ausência de dados faltantes segundo os registros documentados. A amostra reduzida e a existência de classes raras limitam a robustez das estimativas e a generalização a outros contextos educacionais.

8. Limpeza e preparação dos dados da TED 02

A TED 02 inspecionou 145 linhas e 33 colunas do arquivo original, sem encontrar valores ausentes, duplicatas ou códigos fora das faixas documentadas. Não houve imputação, exclusão de linhas ou remoção automática de supostos outliers categóricos. Os nomes das colunas foram padronizados. Para a modelagem, student_id foi retirado do conjunto de preditoras.

Verificação	Registro da TED 02
Registros	145
Valores ausentes	0
Registros duplicados	0
Identificadores únicos no original	145
Códigos fora das faixas documentadas	0
Variáveis preditoras utilizadas na TED 03	31

A ausência de tratamentos adicionais decorreu da inspeção documentada e não de exclusão automática de registros. A base original e os dados tratados permaneceram separados.

9. Análise exploratória de dados da TED 02

9.1 Distribuição da variável-alvo

Classe	Registros	Percentual
Fail	8	5,5%

DD	35	24,1%
DC	24	16,6%
CC	21	14,5%
CB	10	6,9%
BB	17	11,7%
BA	13	9,0%
AA	17	11,7%

O desbalanceamento entre classes fundamentou o uso de F1-macro como métrica principal: a média dá peso igual ao desempenho em cada classe, diferentemente de uma acurácia agregada.

9.2 Horas semanais de estudo

Grupo	N	Média do código de grade
Nenhuma	29	2,90
Menos de 5 horas	74	3,45
6 a 10 horas	30	3,27
11 a 20 horas	8	2,88
Mais de 20 horas	4	2,00

As médias descritivas não mostram progressão linear simples, e os grupos com maior dedicação têm poucas observações.

9.3 Frequência às aulas

O grupo que declarou comparecer sempre teve 110 registros e média codificada de 3,40. O grupo que comparecia às vezes teve 35 registros e média 2,69. A comparação não permite concluir causalidade.

9.4 Percepção sobre projetos e atividades

A percepção positiva reuniu 128 estudantes (média 3,39), a negativa reuniu quatro (média 2,25) e a neutra reuniu 13 (média 1,92). A grande diferença entre os tamanhos dos grupos limita comparações.

9.5 GPA do semestre anterior

Faixa de GPA anterior	N	Média de grade (código)
Abaixo de 2,00	17	2,24
2,00–2,49	38	2,29
2,50–2,99	25	3,92
3,00–3,49	40	3,48
Acima de 3,49	25	4,24

A análise da TED 02 registrou coeficientes V de Cramér aproximados de 0,262 para GPA anterior, 0,201 para percepção de projetos, 0,169 para GPA esperado, 0,144 para horas de estudo e 0,138 para frequência. Associações descritivas não demonstram causalidade nem garantem capacidade preditiva.

10. Relação da exploração com o problema e o MVP

A exploração dá contexto a hábitos e histórico de desempenho, mas não testa o cálculo de prioridades de tarefas. Para esse componente, seriam necessários registros de atividades com prazos, pesos, status e outras informações operacionais.

11. Limitações da análise exploratória

A base é pequena, representa um contexto educacional restrito, possui variáveis autorrelatadas e grupos pouco representados. Não se devem generalizar relações descritivas para outras instituições ou atribuir efeito causal sem desenho apropriado.

12. Síntese da TED 02

A base foi preparada sem imputar valores nem excluir registros; as colunas foram padronizadas e os identificadores foram excluídos de X. As diferenças observadas por histórico acadêmico, frequência e projetos fundamentaram o exame de classificação supervisionada, com cautela devido ao tamanho e composição da amostra.

13. Definição do problema de Machine Learning

A TED 03 investigou classificação supervisionada multiclasse retrospectiva, com grade como alvo e oito categorias preservadas. A finalidade foi verificar, por experimentos reproduzíveis, o comportamento de modelos supervisionados utilizando as variáveis da base tratada. O estudo não equivale a prever notas antes de todos os atributos estarem disponíveis.

14. Conjunto de dados, alvo e seleção de variáveis

O arquivo data/processed/dataset_modelagem.csv contém 145 linhas e 32 colunas: 31 preditoras e grade. O identificador student_id foi excluído. O trabalho preservou todas as 31 preditoras conforme decisão metodológica anterior, tratando seus diferentes tipos conforme a natureza codificada.

15. Preparação para modelagem e prevenção de vazamento

O protocolo adotado foi:

- 16 atributos nominais: OneHotEncoder(handle_unknown='ignore').
- 15 atributos ordinais: códigos preservados como valores ordenados.
- Regressão Logística: StandardScaler sobre os ordinais.
- Árvore de Decisão e Random Forest: ordinais sem padronização.
- Pipelines: transformadores ajustados em cada partição de treinamento, sem utilizar indevidamente as observações do teste.

Essa separação permite tratamento adequado aos diferentes algoritmos e reduz riscos de vazamento do conjunto de teste durante validação.

16. Algoritmos, divisão e avaliação

Foram comparados LogisticRegression(max_iter=3000), DecisionTreeClassifier e RandomForestClassifier, com random_state=42 quando aplicável. A divisão estratificada 80/20 gerou 116 registros de treino e 29 de teste reservado. A comparação ocorreu apenas no conjunto de treino, usando StratifiedKFold(n_splits=5, shuffle=True, random_state=42).

Métrica principal: F1-macro médio da validação cruzada. Métrica complementar: acurácia. O classificador com maior F1-macro médio foi selecionado por regra computacional preestabelecida antes da avaliação do teste. Essa seleção técnica não equivale a uma deliberação formal de equipe.

17. Resultados experimentais

17.1 Comparação na validação cruzada

Classificador	F1-macro médio	Desvio-padrão F1	Acurácia média	DP acurácia	F1 treino
Random Forest	0,227408	0,057315	0,311232	0,074522	1,000000
Árvore de Decisão	0,208232	0,071473	0,242391	0,074874	1,000000
Regressão Logística	0,207314	0,054845	0,276812	0,081405	0,985632

O Random Forest obteve o maior F1-macro médio nessa comparação. A diferença pequena entre os valores e a variabilidade entre as cinco partes não comprovam superioridade geral.

17.2 Teste final reservado

Após a seleção técnica por validação cruzada, o Random Forest foi ajustado aos 116 registros de treinamento e avaliado nos 29 reservados. Resultados da reprodução local já publicada:

Métrica	Resultado
F1-macro no teste	0,288095
Acurácia no teste	0,379310 (37,93%)
Acertos	11 de 29
Classes do alvo	8

17.3 Matriz de confusão do teste

Linhas = classes reais; colunas = classes previstas.

Real / Prevista	Fail	DD	DC	CC	CB	BB	BA	AA
Fail	0	1	1	0	0	0	0	0
DD	0	5	1	0	0	0	0	1
DC	0	5	0	0	0	0	0	0
CC	0	2	0	2	0	0	0	0
CB	0	1	0	1	0	0	0	0
BB	0	3	0	0	0	0	0	0
BA	0	1	0	0	0	0	2	0
AA	0	0	0	0	0	0	1	2

17.4 Relatório por classe

Classe	Precisão	Recall	F1-score	Suporte
Fail	0,000	0,000	0,000	2
DD	0,278	0,714	0,400	7
DC	0,000	0,000	0,000	5
CC	0,667	0,500	0,571	4
CB	0,000	0,000	0,000	2
BB	0,000	0,000	0,000	3
BA	0,667	0,667	0,667	3
AA	0,667	0,667	0,667	3

Visualizações executadas: os gráficos de distribuição de classes, comparação de F1-macro e matriz de confusão estão nas saídas do notebook TED03_REPRODUCAO_LOCAL_EXECUTADA.ipynb (../notebooks/TED03/TED03_REPRODUCAO_LOCAL_EXECUTADA.ipynb).

18. Interpretação dos resultados, erros e limitações

O teste apresentou acurácia de 37,93% e F1-macro de 0,288095. Nenhuma observação das classes Fail, DC, CB e BB foi corretamente classificada no teste reservado. Houve concentração de previsões em DD. O F1-macro próximo de 1,0 no treinamento dos modelos contrasta com resultados muito menores em validação cruzada, situação compatível com risco de sobreajuste.

A reduzida amostra e o número pequeno de observações por classe tornam os indicadores instáveis. Não houve validação externa ou avaliação da estabilidade em outras instituições e turmas. Esses resultados não sustentam uso para decisões individuais sobre estudantes.

19. Privacidade, reprodutibilidade e contribuição ao MVP

O experimento utilizou base pública. A exclusão de student_id entre os preditores não garante anonimização completa. Em aplicações com dados pessoais, seriam necessárias medidas compatíveis com a LGPD, com atenção a finalidade, necessidade, base legal, proteção e transparência. Informações demográficas e familiares podem refletir desigualdades; não foi executada auditoria de equidade por subgrupos.

O trabalho documenta uma demonstração técnica de classificação retrospectiva; não valida previsão antecipada de desempenho nem o algoritmo de priorização do StudyTrack IA. Os experimentos ajudam a identificar requisitos de dados, limites de aplicação e cuidados para uma futura avaliação do MVP.

Rastreabilidade: notebooks/TED03/TED03_modelagem.ipynb (original preservado), notebooks/TED03/TED03_REPRODUCAO_LOCAL_EXECUTADA.ipynb (12 células de código executadas, 17 saídas), docs/TED03_RESULTADOS_TECNICOS_2026-11-02.md (métricas e matriz). A execução registrada é local; não há comprovação de execução no Colab oficial. O Pull Request nº 1 está em rascunho, sem merge para main.

20. Conclusão da TED 03

A TED 03 deu continuidade à seleção, à preparação e à análise exploratória dos dados por meio da comparação de três classificadores multiclasse. O Random Forest liderou a validação cruzada pelo critério técnico anteriormente registrado (F1-macro médio de 0,227408). No teste reservado, obteve F1-macro de 0,288095 e acurácia de 37,93%, com 11 acertos em 29 observações. O desempenho limitado, o risco de sobreajuste, o desequilíbrio e o tamanho das classes impedem considerar o modelo pronto para aplicação operacional.

A investigação contribui para a formação metodológica e para a identificação de requisitos de dados e limitações, mas não demonstra melhoria na priorização de tarefas do MVP. Esta versão consolida evidências técnicas e deverá ter suas interpretações e sua autoria conferidas pelos integrantes antes da submissão.

Referências e materiais de rastreabilidade

- YILMAZ, Nevriye; SEKEROGLU, Boran. Higher Education Students Performance Evaluation. UCI Machine Learning Repository. DOI: 10.24432/C51G82 (https://doi.org/10.24432/C51G82). Dados coletados em 2019, disponibilizados na UCI em 2023.
- SCIKIT-LEARN DEVELOPERS. Cross-validation: evaluating estimator performance (https://scikit-learn.org/stable/modules/cross_validation.html). Documentação.
- STUDYTRACK IA. Repositório e TEDs anteriores (https://github.com/Francisco-alt-coder/StudyTrack_IA). PDFs TED_01_Big_Data_StudyTrack_IA.pdf e TED02_StudyTrack_.pdf.
- STUDYTRACK IA. Pull Request nº 1 — TED 03 (https://github.com/Francisco-alt-coder/StudyTrack_IA/pull/1): notebook de reprodução local e resultados técnicos de 02/11/2026.

Registro de uso da Inteligência Artificial

Ferramenta: ChatGPT (OpenAI). Finalidade: conferência dos arquivos públicos e dos resultados, reprodução técnica local, revisão de consistência e organização editorial do Documento Técnico v3.0. Apoio prestado: revisão documental, explicações de código, comparação de métricas e preparação de materiais derivados de evidências já existentes. A IA não executou o Google Colab oficial, não aprovou o trabalho pelos integrantes e não validou o desempenho do modelo em produção.

Validação: confronto entre matriz, acurácia e contagens, registro de execução local no notebook e conferência de arquivos e fontes. A equipe permanece responsável por revisar as interpretações, a autoria e o histórico de consultas efetivamente utilizadas.

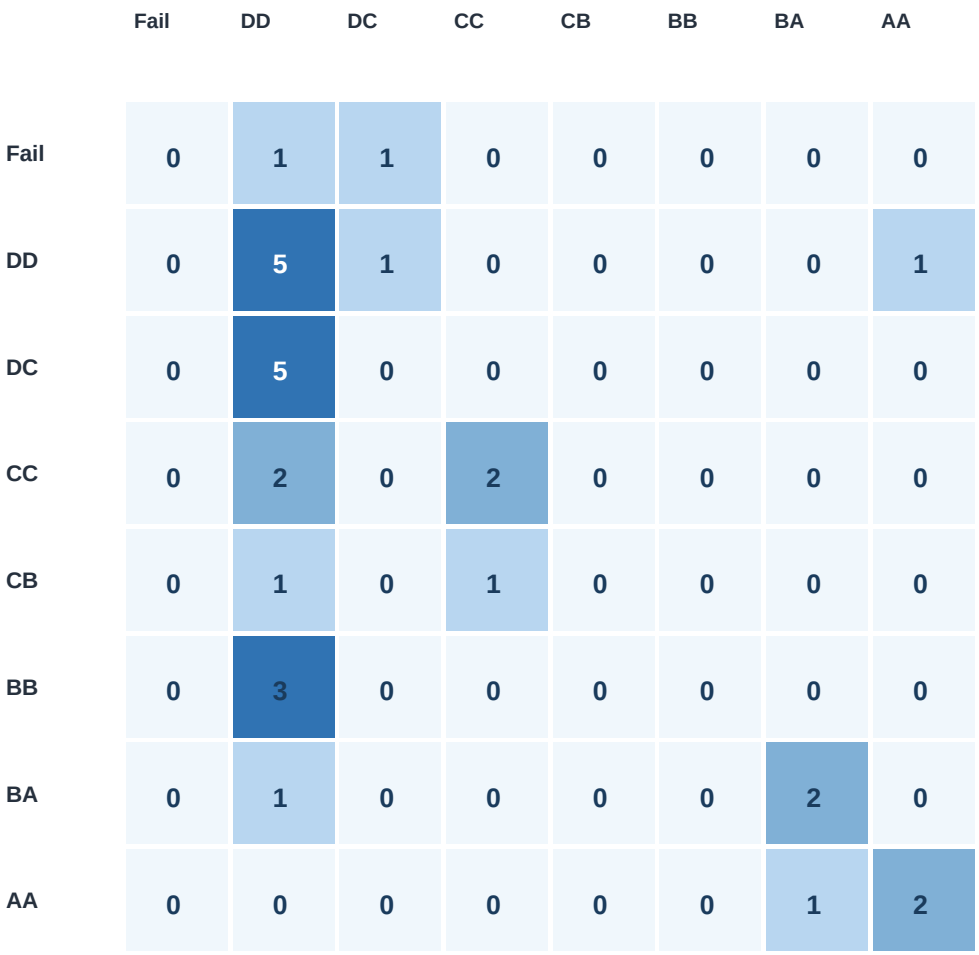
Privacidade: esta consolidação usou dados públicos, sem inserção de dados pessoais sigilosos ou credenciais.

Anexo visual — síntese dos resultados

Figura A: comparação descritiva do F1-macro médio na validação cruzada de cinco partes (116 registros de treinamento). Fonte: resultados técnicos da TED 03.



Matriz de confusão — teste reservado



	Fail	DD	DC	CC	CB	BB	BA	AA
Fail	0	1	1	0	0	0	0	0
DD	0	5	1	0	0	0	0	1
DC	0	5	0	0	0	0	0	0
CC	0	2	0	2	0	0	0	0
CB	0	1	0	1	0	0	0	0
BB	0	3	0	0	0	0	0	0
BA	0	1	0	0	0	0	2	0
AA	0	0	0	0	0	0	1	2

Figura B: linhas são classes reais, colunas são classes previstas. Acertos na diagonal: 11 de 29; acurácia 37,93%. Esta figura reproduz os números publicados no relatório técnico.