

CENTRO UNIVERSITÁRIO DE BALSAS – UNIBALSAS
CURSO DE ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

CAIO VINÍCIUS LIMA SOARES
DAVID RODRIGUES COSTA
FRANCISCO WESLEY DE SOUZA DIAS
PEDRO HENRIQUE GUEDES

STUDYTRACK IA: TRATAMENTO, LIMPEZA, SANEAMENTO E ANÁLISE
EXPLORATÓRIA DOS DADOS
TED 02 – BIG DATA E CIÊNCIAS DE DADOS

Balsas – MA
2026



SUMÁRIO

1 INTRODUÇÃO	3
2 PROBLEMA E SOLUÇÃO.....	3
3 NECESSIDADES DE DADOS.....	3
4 CONJUNTO DE DADOS SELECIONADO	4
5 PRINCIPAIS VARIÁVEIS	4
6 JUSTIFICATIVA DA ESCOLHA	5
7 QUALIDADE E LIMITAÇÕES IDENTIFICADAS NA TED 01	5
8 LIMPEZA E PREPARAÇÃO DOS DADOS	5
9 ANÁLISE EXPLORATÓRIA DE DADOS.....	7
10 RELAÇÃO DOS RESULTADOS COM O PROBLEMA E O MVP DO STUDYTRACK IA.....	13
11 LIMITAÇÕES DA ANÁLISE.....	13
12 CONCLUSÃO.....	14
REFERÊNCIAS.....	14



1 INTRODUÇÃO

O projeto StudyTrack IA foi desenvolvido com o objetivo de auxiliar estudantes na organização e priorização de suas atividades acadêmicas. A proposta reúne informações relacionadas às disciplinas, atividades, avaliações e compromissos do estudante, permitindo uma visão mais organizada da rotina acadêmica.

Na disciplina de Big Data e Ciências de Dados, a TED 01 definiu as necessidades de dados e selecionou um conjunto público para apoiar as etapas de análise e modelagem. Nesta TED 02, o mesmo conjunto é inspecionado, preparado e analisado de forma exploratória, com o objetivo de verificar sua qualidade e compreender o que os dados revelam sobre hábitos e desempenho acadêmico.

2 PROBLEMA E SOLUÇÃO

A rotina universitária envolve disciplinas, avaliações, trabalhos e diferentes prazos, o que pode dificultar a organização e a definição de prioridades.

O StudyTrack IA propõe centralizar essas informações e auxiliar estudantes universitários no acompanhamento das atividades e na organização dos estudos. O MVP prevê cadastro de disciplinas e atividades, acompanhamento de prazos, calendário, indicação de prioridade e painel de acompanhamento acadêmico.

3 NECESSIDADES DE DADOS

Para apoiar o StudyTrack IA, são relevantes dados relacionados ao comportamento e ao desempenho acadêmico dos estudantes. Entre as informações de interesse estão:

Informação	Relação com o projeto
Horas de estudo	Auxilia na análise da dedicação acadêmica
Frequência às aulas	Indica participação acadêmica
Preparação para avaliações	Relaciona organização e desempenho
Atividades e projetos	Permite observar sua influência no resultado
Desempenho anterior	Possibilita acompanhar o histórico acadêmico
Resultado acadêmico	Permite avaliar o desempenho obtido



Esses dados não representam todas as funcionalidades do StudyTrack IA, mas permitem investigar fatores relacionados à organização dos estudos e ao desempenho acadêmico.

4 CONJUNTO DE DADOS SELECIONADO

Foi selecionado o conjunto de dados Higher Education Students Performance Evaluation, disponibilizado pelo UCI Machine Learning Repository. A base reúne informações sobre hábitos e desempenho acadêmico de estudantes do ensino superior.

Característica	Informação
Nome	Higher Education Students Performance Evaluation
Fonte	UCI Machine Learning Repository
Quantidade de registros	145
Variáveis preditoras	31
Variável-alvo	Desempenho acadêmico final (GRADE)
Formato	CSV
Contexto	Ensino superior
Tipo	Dados tabulares/categóricos codificados
Licença	Creative Commons Attribution 4.0
Valores ausentes	Nenhum, confirmado na inspeção da TED 02

5 PRINCIPAIS VARIÁVEIS

Variável	Possível utilização
Horas semanais de estudo	Analisar dedicação aos estudos
Frequência às aulas	Avaliar participação acadêmica
Preparação para avaliações	Observar hábitos de planejamento
Impacto de projetos e atividades	Investigar relação com desempenho
Anotações durante as aulas	Analisar hábitos acadêmicos
Desempenho do semestre anterior	Comparar histórico acadêmico
Identificação do curso	Diferenciar contextos de estudo
Nota final	Representar o desempenho acadêmico

As variáveis originais estão codificadas numericamente. Por isso, os códigos foram interpretados conforme a documentação oficial da base e não como medidas numéricas contínuas.



6 JUSTIFICATIVA DA ESCOLHA

A base foi escolhida por apresentar dados relacionados ao contexto acadêmico e por possuir uma estrutura simples para análise com Python e Pandas. Variáveis como horas de estudo, frequência, preparação para avaliações e desempenho apresentam relação com a proposta do StudyTrack IA de apoiar a organização acadêmica.

Entretanto, a base não possui informações sobre prazos, pesos de atividades, calendário ou prioridade das tarefas. Por isso, sua contribuição está principalmente na análise dos hábitos e do desempenho acadêmico.

7 QUALIDADE E LIMITAÇÕES IDENTIFICADAS NA TED 01

Na TED 01 foi registrado, com base na fonte original, que a base possui 145 registros e não apresenta valores ausentes. Também foram apontadas como limitações a quantidade reduzida de registros, a ausência de informações diretamente relacionadas à priorização de tarefas e o fato de os dados terem sido coletados em um contexto educacional específico.

8 LIMPEZA E PREPARAÇÃO DOS DADOS

8.1 Inspeção inicial

O arquivo DATA (1).csv foi carregado com a biblioteca Pandas. A inspeção confirmou 145 registros e 33 colunas no arquivo: um identificador de estudante, 30 atributos codificados, o identificador do curso e a variável de saída GRADE. Foram encontrados 145 identificadores distintos, o que confirma a inexistência de repetição do identificador principal.

Verificação	Resultado
Registros	145
Colunas no arquivo	33
Valores ausentes	0
Registros duplicados	0
Duplicados desconsiderando STUDENT ID	0
IDs de estudante únicos	145
Códigos fora das faixas documentadas	0



8.2 Problemas de qualidade encontrados

A inspeção não encontrou valores ausentes, registros duplicados ou códigos fora das faixas previstas na documentação. Portanto, não houve necessidade de preencher valores, excluir observações ou corrigir categorias. O principal ponto de preparação foi tornar a estrutura mais legível e apropriada para as análises posteriores.

As colunas numeradas de 1 a 30 representam categorias codificadas, mesmo estando armazenadas como números inteiros. Tratá-las como variáveis contínuas poderia produzir interpretações inadequadas. Assim, os códigos foram mantidos, mas as colunas foram renomeadas com nomes descritivos e interpretadas de acordo com sua natureza categórica ou ordinal.

8.3 Tratamentos realizados e justificativas

Tratamento	Decisão	Justificativa
Valores ausentes	Nenhuma imputação	A base possui zero valores ausentes.
Duplicatas	Nenhuma remoção	Não foram encontrados registros duplicados, inclusive ao desconsiderar o identificador.
Faixas inválidas	Nenhuma correção	Todos os códigos estão dentro das faixas previstas pela documentação.
Nomes das colunas	Renomeados	Os nomes 1 a 30 foram substituídos por nomes descritivos para melhorar legibilidade e reprodutibilidade.
STUDENT ID	Mantido na base tratada e excluído da base de modelagem	É útil para rastreabilidade, mas não possui significado preditivo.
Categorias raras	Mantidas	Baixa frequência não significa erro; sua remoção reduziria ainda mais uma base já pequena.
Outliers	Sem remoção automática	A maioria das variáveis é categórica codificada; aplicar IQR ou z-score aos códigos seria inadequado.

8.4 Descrição da base após o tratamento

Após o processo de preparação, a base continua com 145 registros. Nenhuma linha foi removida, pois não foram encontrados problemas que justificassem exclusão. A



versão tratada contém nomes de colunas descritivos. Também foi criada uma versão destinada à modelagem sem o atributo `student_id`.

Característica	Base original	Base tratada
Registros	145	145
Colunas	33	33
Valores ausentes	0	0
Duplicados	0	0
Códigos inválidos	0	0
Nomes das variáveis	Códigos numéricos	Nomes descritivos
Identificador	STUDENT ID	student_id, mantido apenas para rastreabilidade


9 ANÁLISE EXPLORATÓRIA DE DADOS

9.1 Distribuição da variável-alvo

A variável GRADE possui oito classes, de 0 (Fail) a 7 (AA). A distribuição não é uniforme. A classe DD é a mais frequente, com 35 estudantes (24,1%), enquanto a classe Fail possui 8 registros (5,5%). As classes DC e CC apresentam 24 (16,6%) e 21 (14,5%) registros, respectivamente. Essa distribuição deve ser considerada em uma futura etapa de classificação, pois algumas classes possuem quantidade significativamente menor de exemplos.

Classe	Significado	Quantidade	Percentual
0	Fail	8	5,5%
1	DD	35	24,1%
2	DC	24	16,6%
3	CC	21	14,5%
4	CB	10	6,9%
5	BB	17	11,7%
6	BA	13	9,0%
7	AA	17	11,7%





Distribuição das classes de nota final.

A visualização confirma que o conjunto apresenta concentração maior nas classes intermediárias e inferiores, mas mantém exemplos em todas as oito classes. Isso é útil para análise, embora a desigualdade entre as frequências possa afetar modelos de classificação se não for considerada posteriormente.

9.2 Horas semanais de estudo

Em relação às horas semanais de estudo, 74 estudantes declararam estudar menos de cinco horas por semana, constituindo a categoria mais frequente. A média da classe de nota foi 3,45 nesse grupo, enquanto estudantes entre 6 e 10 horas apresentaram média 3,27. Os grupos de 11 a 20 horas e acima de 20 horas possuem apenas 8 e 4 registros, respectivamente, o que impede concluir que suas médias menores representam um padrão geral.

Horas de estudo	N	Média da classe de nota	Mediana
Nenhuma	29	2,90	2
<5 horas	74	3,45	3
6–10 horas	30	3,27	3
11–20 horas	8	2,88	3
>20 horas	4	2,00	2

Figura 2 – Média da classe de nota por faixa de horas semanais de estudo.

Os resultados não mostram uma relação linear simples entre maior quantidade de horas declaradas e maior nota. Isso reforça que o tempo de estudo, isoladamente, não explica o desempenho e deve ser analisado em conjunto com outros fatores.

9.3 Frequência às aulas

A base possui 110 estudantes classificados como sempre presentes e 35 como presentes às vezes; não existem registros na categoria nunca. O grupo com frequência sempre apresentou média de classe de nota 3,40, enquanto o grupo com frequência às vezes apresentou média 2,69.

Frequência	N	Média da classe de nota	Mediana
Sempre	110	3,40	3
Às vezes	35	2,69	2




Figura 3 – Média da classe de nota segundo a frequência às aulas.



A diferença observada é compatível com a hipótese de que maior participação acadêmica pode estar associada a melhor desempenho. Contudo, a análise é descritiva e não demonstra causalidade.

9.4 Impacto de projetos e atividades

A maior parte dos estudantes, 128 de 145, avaliou como positivo o impacto de projetos e atividades sobre o próprio sucesso acadêmico. Nesse grupo, a média da classe de nota foi 3,39. Os grupos negativo e neutro apresentam apenas 4 e 13 registros, respectivamente, com médias 2,25 e 1,92.

Impacto percebido	N	Média da classe de nota
Positivo	128	3,39
Negativo	4	2,25
Neutro	13	1,92




Figura 4 – Média da classe de nota segundo o impacto percebido de projetos e atividades.

O padrão é relevante para o StudyTrack IA porque sugere que atividades acadêmicas e projetos podem ser considerados como elementos importantes na



compreensão da rotina do estudante. Entretanto, a grande diferença de tamanho entre as categorias exige cautela na interpretação.

9.5 Desempenho no semestre anterior

O desempenho anterior apresenta um padrão mais consistente com a nota final. Estudantes com GPA anterior acima de 3,49 tiveram média de classe de nota 4,24, enquanto as duas menores faixas de GPA apresentaram médias 2,24 e 2,29. A categoria de 2,50 a 2,99 apresentou média 3,92.

GPA anterior	N	Média da classe de nota	Mediana
<2,00	17	2,24	2
2,00–2,49	38	2,29	1
2,50–2,99	25	3,92	4
3,00–3,49	40	3,48	3
>3,49	25	4,24	4




Figura 5 – Média da classe de nota segundo o GPA do semestre anterior.

Esse resultado indica que o histórico acadêmico contém informação relevante para compreender o desempenho atual. Para o MVP, essa variável pode contribuir futuramente para mecanismos de acompanhamento e sinalização de estudantes.



9.6 Relações entre variáveis

Como a maioria dos atributos é categórica, foi utilizada a medida V de Cramér para observar a intensidade de associação entre categorias e a nota final. Entre as variáveis diretamente relacionadas ao projeto, destacaram-se o GPA do semestre anterior ($V \approx 0,262$), o impacto percebido de projetos e atividades ($V \approx 0,201$), o GPA esperado na graduação ($V \approx 0,169$), as horas semanais de estudo ($V \approx 0,144$) e a frequência às aulas ($V \approx 0,138$). Esses valores indicam associações fracas a moderadas e não representam relações causais.

O identificador do curso também apresentou associação com a nota, o que sugere que o contexto da disciplina pode influenciar a distribuição das avaliações. Por esse motivo, comparar estudantes de cursos diferentes sem considerar essa variável pode produzir conclusões inadequadas.

10 RELAÇÃO DOS RESULTADOS COM O PROBLEMA E O MVP DO STUDYTRACK IA

A análise mostra que o desempenho acadêmico não depende de um único comportamento. Variáveis relacionadas ao histórico acadêmico, participação em aula e percepção sobre projetos apresentam diferenças de desempenho entre seus grupos. Em contrapartida, as horas de estudo não exibiram uma progressão linear, demonstrando que simplesmente aumentar o tempo declarado de estudo não é suficiente para explicar a nota final.

Resultado da EDA	Relação com o StudyTrack IA
Histórico acadêmico apresentou associação com a nota final	O painel pode utilizar desempenho anterior como contexto para acompanhamento, sem tratá-lo como sentença sobre o estudante.
Frequência sempre apresentou média superior à frequência às vezes	A participação acadêmica pode ser considerada como indicador contextual no acompanhamento.
Projetos/atividades avaliados como positivos concentram maior média	O sistema pode registrar e acompanhar atividades acadêmicas relevantes, ajudando o estudante a visualizar sua rotina.
Horas de estudo não apresentaram relação linear com a nota	O MVP não deve priorizar tarefas apenas com base em tempo de estudo; prazos, pesos e contexto continuam necessários.
Base não contém prazos, pesos ou calendário	O dataset não é suficiente para treinar diretamente o mecanismo de priorização do MVP e deverá ser complementado por dados próprios do StudyTrack.



Dessa forma, a principal contribuição desta base para o projeto é apoiar a compreensão de hábitos e desempenho acadêmico. Para o mecanismo central de priorização de tarefas do StudyTrack IA, ainda serão necessários dados próprios contendo prazo, peso da atividade, disciplina, status, esforço estimado e outros atributos diretamente ligados ao planejamento acadêmico.

11 LIMITAÇÕES DA ANÁLISE

A base possui apenas 145 registros e foi coletada em um contexto educacional específico. Portanto, os resultados não devem ser generalizados para todos os estudantes ou instituições. Além disso, muitas variáveis são respostas categóricas e autorrelatadas, o que limita interpretações quantitativas mais precisas. As comparações apresentadas são exploratórias e não estabelecem causalidade.

Outro ponto importante é que algumas categorias possuem poucos registros. Por exemplo, apenas quatro estudantes informaram estudar mais de 20 horas por semana e apenas dois registros aparecem na categoria “nunca” para o momento de preparação para provas. Médias calculadas para grupos tão pequenos podem variar bastante e devem ser interpretadas com cautela.

12 CONCLUSÃO

A TED 02 permitiu transformar o conjunto de dados selecionado na etapa anterior em uma base mais organizada e compreensível para análise. A inspeção confirmou que o arquivo possui boa integridade: não foram encontrados valores ausentes, duplicatas ou códigos fora das faixas documentadas. Assim, a preparação concentrou-se na padronização dos nomes das variáveis, interpretação correta dos códigos categóricos e separação do identificador para futura modelagem.

A análise exploratória indicou que o desempenho anterior, a frequência às aulas e a percepção sobre projetos e atividades apresentam diferenças relevantes entre seus grupos. Também mostrou que as horas semanais de estudo não possuem uma relação linear simples com a nota final. Esses resultados contribuem para compreender o problema acadêmico abordado pelo StudyTrack IA.



REFERÊNCIAS

YILMAZ, Nevriye; ŞEKEROĞLU, Boran. Higher Education Students Performance Evaluation. UCI Machine Learning Repository, 2019. DOI: 10.24432/C51G82.

Disponível em:

<https://archive.ics.uci.edu/dataset/856/higher+education+students+performance+evaluation>. Acesso em: 26 set. 2026.

OLIVEIRA, Manuel Joaquim Silva; CAETANO, Guedes; DANIEL, Eulanda Maria Pedro. Usando a mineração de dados para predição de desempenho de alunos nas disciplinas de Português e Matemática. Revista de Educação do Vale do Arinos, v. 5, n. 2, 2018. DOI: 10.30681/relva.v5i2.3403.

PANDAS DEVELOPMENT TEAM. pandas documentation. Documentação oficial da biblioteca Pandas, 2026. Disponível em: <https://pandas.pydata.org/docs/>. Acesso em: 26 set. 2026.

